

# Análisis de Componentes Principales

## Con Python

Jose Luis Paniagua Jaramillo  
jlpaniagua@uao.edu.co

- 1 Reducción de Dimensionalidad
  - PCA
- 2 Implementacion en Python
  - Desde cero
  - Usando la librería scikit-learn
- 3 Referencias

- 1 Reducción de Dimensionalidad
  - PCA
- 2 Implementacion en Python
  - Desde cero
  - Usando la librería scikit-learn
- 3 Referencias




Figura: [1]

## El problema de la dimensionalidad

- alta probabilidad de presentarse sobre entrenamiento (overfitting).
- dificultades para la visualización.
- afecta la velocidad en el proceso de entrenamiento.

- 1 Reducción de Dimensionalidad
  - PCA
- 2 Implementacion en Python
  - Desde cero
  - Usando la librería scikit-learn
- 3 Referencias

# Principal Component Analysis - PCA I

original 3D dataset




Figura: [1]

2D dataset after projection





Figura: [1]

# Principal Component Analysis - PCA II



- se debe seleccionar el eje (hiperplano) que preserve la mayor varianza.
- mayor varianza, implica menos pérdida de información.
- el objetivo es proyectar sobre los ejes que minimicen la distancia entre los datos originales y su proyección.

# Agenda

- 1 Reducción de Dimensionalidad
  - PCA
- 2 Implementacion en Python
  - Desde cero
  - Usando la librería scikit-learn
- 3 Referencias



# Agenda

- 1 Reducción de Dimensionalidad
  - PCA
- 2 Implementacion en Python
  - Desde cero
  - Usando la librería scikit-learn
- 3 Referencias

## Singular Value Decomposition (SVD)

SVD es una técnica estándar de factorización de matrices.

$$X = U\Sigma V^T$$

- $U$  y  $V$  son matrices unitarias.
- $\Sigma$  es una matriz diagonal con  $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$

# Calculo de los Componentes Principales II

¿Qué imagen enviaría?

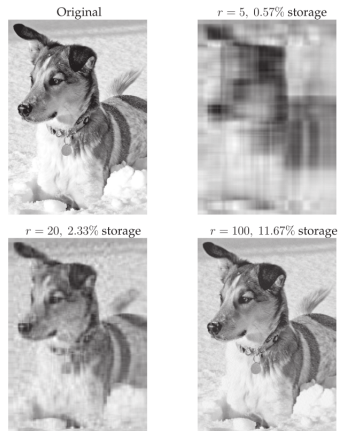


Figura: source[2]

# Calculo de los Componentes Principales III

The Singular Value Decomposition (SVD) separa cualquier matriz en piezas sencillas (escalado y rotación)





Figura: source: wikipedia

# Calculo de los Componentes Principales IV


Transformación Lineal = Matriz



$$M = \begin{bmatrix} 2 & 0 \\ 3 & 4 \end{bmatrix}$$

(1, 0)      (2, 3)

(1, 0)      (2, 3)



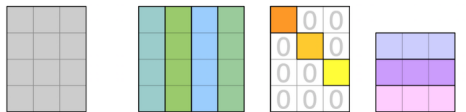
SVD

$$M = U\Sigma V'$$

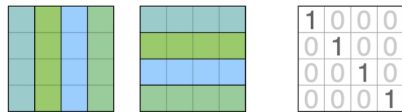
$$\begin{bmatrix} 2 & 0 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix} \begin{bmatrix} \cos \phi & \sin \phi \\ -\sin \phi & \cos \phi \end{bmatrix}$$

- $U$  and  $V'$  are unitary.
- $\Sigma$  is diagonal with  $\sigma_1 \geq \sigma_2 \geq \sigma_3 \cdots \geq 0$

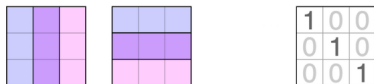
# Calculo de los Componentes Principales VI



$$\mathbf{X}_{n \times m} = \mathbf{U}_{n \times n} \mathbf{\Sigma}_{n \times m} \mathbf{V}^*_{m \times m}$$



$$\mathbf{U}_{n \times n} \mathbf{U}^*_{n \times n} = \mathbf{I}_n$$



$$\mathbf{V}_{m \times m} \mathbf{V}^*_{m \times m} = \mathbf{I}_m$$

# Calculo de los Componentes Principales VII

1	1	1	1	1	1
1	1	1	1	1	1
1	1	1	1	1	1
1	1	1	1	1	1
1	1	1	1	1	1
1	1	1	1	1	1

$$=$$

1
1
1
1
1
1

1	1	1	1	1	1
---	---	---	---	---	---



# Calculo de los Componentes Principales VIII

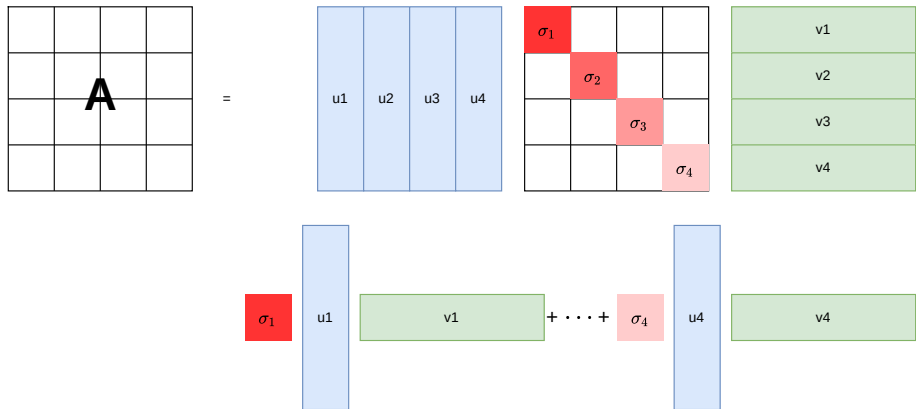
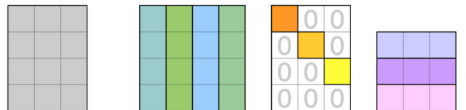



Figura: source:[3]


# Calculo de los Componentes Principales IX



$$\mathbf{X}_{n \times m} = \mathbf{U}_{n \times n} \mathbf{\Sigma}_{n \times m} \mathbf{V}^*_{m \times m}$$



$$\mathbf{U}_{n \times n} \mathbf{U}^*_{n \times n} = \mathbf{I}_n$$



$$\mathbf{V}_{m \times m} \mathbf{V}^*_{m \times m} = \mathbf{I}_m$$

$V$  contiene los vectores unitarios que definen los componentes principales.

$$V = \begin{bmatrix} | & | & \dots & | \\ c_1 & c_2 & \dots & c_n \\ | & | & \dots & | \end{bmatrix}$$

## Reduccion de Dimensionalidad

Después de identificar los componentes principales, es posible realizar la reducción de dimensional proyectando la matriz  $X$  en el hiperplano definido por los primeros  $d$  componentes principales.

$$X_{d-proj} = XW_d$$


Ejemplo: iris dataset

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

# Agenda

- 1 Reducción de Dimensionalidad
  - PCA
- 2 Implementacion en Python
  - Desde cero
  - Usando la librería scikit-learn
- 3 Referencias

# Ejemplo: iris dataset



# Agenda

- 1 Reducción de Dimensionalidad
  - PCA
- 2 Implementacion en Python
  - Desde cero
  - Usando la librería scikit-learn
- 3 Referencias



Aurélien Géron.

*Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems.*

O'Reilly Media, 2019.



Steven L Brunton and J Nathan Kutz.

*Data-driven science and engineering: Machine learning, dynamical systems, and control.*

Cambridge University Press, 2019.



Luis Serrano.

*Grokking Machine Learning.*

Simon and Schuster, 2021.

[https://towardsdatascience.com/  
principal-component-analysis-pca-from-scratch-in-python-7f3e2a540c51](https://towardsdatascience.com/principal-component-analysis-pca-from-scratch-in-python-7f3e2a540c51)  
<https://scikit-learn.org/stable/index.html>